目次

- 1. テーマ設定の背景
- 2. 本プロジェクトでの目標
- 3. 使用した教材
- 4. プログラムの概要
- 5. 実験
 - (ア) 実験1
 - (イ) 実験 2
 - (ウ) 実験3
- 6. 考察
- 7. 今後の展望

1. テーマ設定の背景

情報化が進んだ現在では、あらゆる情報が容易に入手できるようになった。一方で、自分にとって、不必要な情報も得られるようになった。不必要な情報かどうか判断するには、文章を読む必要がある。読んだ分だけ時間を浪費する必要がある。また、必要な情報であっても、その情報が長文で書かれていた場合、自分が知りたい情報を見つけ出すのにも時間を浪費する必要がある。より詳しく説明すればするほど、文章は長く、複雑になる傾向がある。そのような文章に対して、「少ない情報量で文章の内容をつかみたい」という思いから「文章の簡略化」というテーマに決めた。

2. 本プロジェクトでの目標

本プロジェクトでは、「新聞記事や長い文章の内容が簡単に読み取れること」を目標とする。新聞記事は、タイトルを見てその記事を読むかどうか決める傾向にある。しかし、タイトルだけでは本当に読みたい記事かどうか判断するのは難しい。そこで、記事のキーワードとなる単語がわかることで、効率よく読みたい記事を選択できる。

3. 使用した教材

使用した教材は以下の通りである。

- · 東京新聞: https://www.tokyo-np.co.jp/
- ・ 法政大学情報科学部ホームページ:https://cis.hosei.ac.jp/

- 4. プログラムの概要
- I. テキストファイルを読み込み、変数(text)に代入する。
- II. text を形態素解析し、得られる情報の左から 3 個分(単語、品詞 1、品詞 2)を取り出し、リスト(part_list)に保存する。
- III. part_list の情報から接続する単語を決める。以下、接続するときに利用した条件式である。
 - (ア)「名詞」「名詞」、あるいは「接頭詞」「名詞」なら、セットにして「名詞」にする。
 - ① その中で、前の単語が「非自立語」以外なら、セットにして「名詞」にする。
 - (イ)「名詞」「アルファベット」、あるいは「アルファベット」「名詞」なら、セットに して「名詞」にする。
 - (ウ)「動詞」「動詞」なら、セットにして「動詞」にする。
 - (エ)「動詞|「助動詞|なら、セットにして「動詞|にする。
 - (オ)「名詞」「動詞」なら、セットにして「動詞」にする。
 - (カ)「形容詞」「名詞」なら、セットにして「名詞」にする。
 - (キ)「動詞」「助詞」「動詞」なら、セットにして「動詞」にする。
 - (ク)「名詞」「する」なら、セットにして「動詞」にする。
 - (ケ)「名詞」「助詞(副詞化)」なら、セットにして「副詞」にする。
 - (コ)「助詞」「助詞」なら、セットにして「助詞」にする。
 - (サ)「助動詞」「助動詞」なら、セットにして「助動詞」にする。
 - (シ)「名詞」「・」「名詞」なら、セットにして「名詞」にする。
 - (ス)「動詞」「助詞(接続助詞)」なら、セットにして「動詞」にする。
 - (セ)「」で囲まれた文なら、「」の中身をセットにして「セリフ」にする。
- IV. part_list の要素に対して、以下を繰り返す。
 - (ア) ノードの生成
 - ① その単語が「名詞」または「セリフ」なら追加する。
 - 1. その名詞の中で「非自立語」以外なら追加する。
 - (イ) リンクの生成
 - ① 「名詞」と「名詞」の間にある動詞、副詞、助詞に対して以下を行う。
 - 1. 動詞:リンクのラベルに追加する。
 - 2. 副詞:リンクのラベルに追加する。
 - 3. 助詞
 - (ア)「が」、「は」、「も」なら、リンクを赤にする。
 - (イ)「で」、「に」、「から」、「へ」なら、リンクを青にする。
 - (ウ)「を」なら、リンクをピンクにする。
 - (エ)「連体格」なら、リンクを緑にする。

5-1. 実験1

タイトル:「ロシア産原油、価格上限を初突破 制裁効果、薄れる恐れ」

本文:ロシア産原油の価格が12日、G7やEUなどが対ロ経済制裁で設けた上限の1バレル=60ドルを初めて突破した。主要産油国の追加減産で原油相場が押し上げられた。ウクライナ侵攻の戦費に充てるロシアの原油収入を抑える制裁の効果が薄れる恐れがある。G7が追加措置を検討するかどうかが焦点になる。英調査会社が明らかにした。ロシアの代表的油種ウラル原油の価格は上限価格が設けられた昨年12月以降、一時40ドルを割った。しかし、主要産油国でつくる「OPECプラス」を主導するサウジアラビアやロシアが追加減産を決めたこともあって持ち直し、12日に60ドル台に乗せた。制裁はロシア産原油の価格高騰を抑えることを狙って導入された。60ドルを上回る価格で取引される原油には、海上輸送に必要な保険の契約をさせないことが柱。その後、ガソリンなどの石油製品にも拡大した。ただ上限価格の追加制裁に賛同する国は一部に限られ、中国やインドは欧州に代わってロシアから石油を積極的に輸入している。

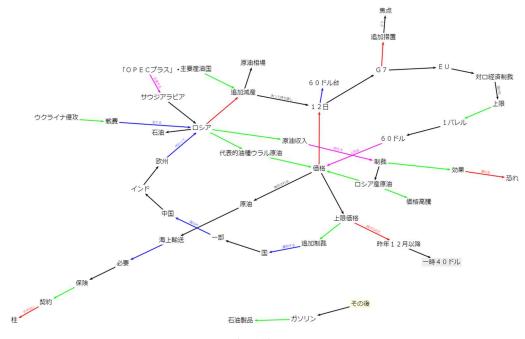


図1出力結果1

タイトル:「夢見た舞台で最高の形」大谷翔平「二刀流」締めで MVP 特ジャパン 14 年ぶり 3 度目世界一/

本文:野球の第5回ワールド・ベースボール・クラシックは21日、米フロリダ州マイアミ で決勝戦が行われ、日本は前回覇者の米国を3-2で下し、2009年第2回大会以来 14年ぶり3度目の世界一に輝いた。先発・今永が二回、ターナーに大会5号ソロを 浴びて先制を許したが、村上の1号ソロや岡本の2号ソロなどで加点。鉄壁の救援 陣で米国の猛攻をしのぎ、八回はダルビッシュがソロ被弾しながらも1点リードで 最終回へ。大谷は打席とブルペンを往復しながらも九回に登板、最後の打者である同 僚で米国チーム主将のトラウトを140キロのスライダーで空振り三振に打ち取り、 勝利を決め、大会 MVP を獲得した。侍ジャパンのメンバー達はステージで優勝トロ フィーを掲げて喜びを爆発。マウンド付近では栗山監督が10回、ダルビッシュ、大 谷、ヌートバーの3人が3回ずつ胴上げされた。中継局インタビューで大谷は「夢 見ていたところなので本当に嬉しい。接戦のいいゲームで緊張したけど、何とか抑え られて良かった。四球を出してしまったけどゲッツーになって最高の形で迎えられ て、最高の結果になって良かった | と興奮気味。子どもの頃からの夢だった大舞台で の世界一に「正直、終わってしまうのが淋しい気持ちがあるけど、それぞれチームに 帰ってシーズンが始まる。最高の形で終われて、みんなが自分たちの仕事をして、粘 り強く最後まで諦めず、監督を優勝させられて良かった」と喜びを語った。

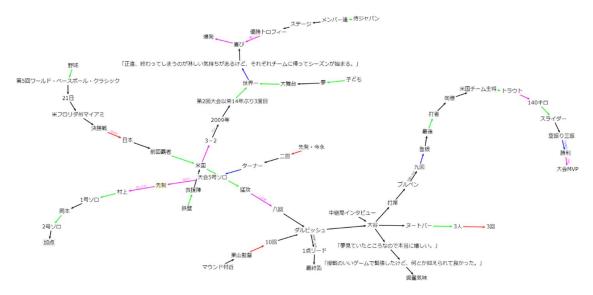


図2出力結果2

タイトル:「法政大学情報科学部ホームページ」

本文:皆さんは、日々の生活の中で、WEBの検索や、SNS による友達とのメッセージ交換 など、インターネットを通じて様々な情報を利用していることでしょう。また、スマ ートフォンを持ち歩き、買い物の支払いなどを重ねていくと、皆さん自身が行動や購 買履歴といった情報を生み出し、それを束ねたビッグデータが分析され、次の商品や サービスの開発に使われていることを知っていますか。現在の社会は、情報社会と呼 ばれています。皆さんの身の回りに起きていることも、様々な方法でデータ化され、 蓄積されています。その情報を、他の様々な情報と組み合わせて分析することで、新 しい価値を生み出し、利用していく社会になっています。このような情報社会におい て、情報を効果的に扱う手法を考えるのが情報科学です。私たちは、生活の中の状況 を、自然に理解し、意味を与え、生活を豊かにするために利用しています。猫を見れ ば、それが猫だとわかり、頭をそっとなでてあげることができます。これと同じこと を機械にやってもらうには、どのようにしたらよいでしょう。写真を詳細に分析して、 目やひげなどの色や形を取り出して、猫であると推定します。あるいは、最近話題の 人工知能の研究では、大量の猫の写真を与えることで、それと似ているかか否かを自 動判定する仕組みを作り出せることが明らかになり、その応用領域が注目を集めて います。大切な情報でも、何もしないままでは、その大切さに気がつかないうちに、 消えてなくなってしまいます。大切な情報を見つけ出すこと、そして、より価値の高 い情報に作り上げること、それを適切な時に、適切な人に伝えることが必要です。法 政大学情報科学部は、インターネットが急速に拡大し、情報への期待が高まり始めた 2000年に創設され、今年で20年になります。この20年間、「新しい概念づくり」を 目標に、初学者が情報科学を学ぶための教育方法を試行錯誤してきました。是非、カ リキュラムを確認してみてください。情報科学に必要な数学・物理の基礎から、コン ピュータの基本知識、人工知能などの専門領域に至るまでの科目群を用意しました。 知識は学ぶだけではなく、自らがアイデアを出し、新しい価値を見つけていく創造力 が必要です。情報科学部は、教員と学生の距離を近くして、皆さんの将来を切り拓く 力を培えるよう、様々な場を用意しています。一緒に、未来をデザインしませんか。

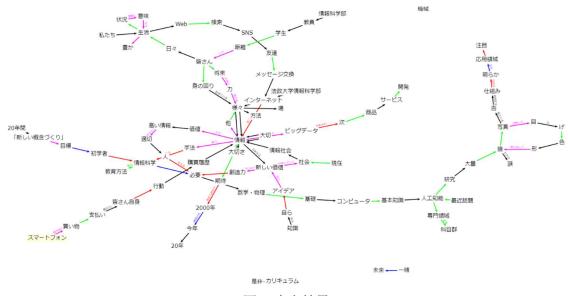


図3出力結果3

6. 考察

3つの実験とも、表示する単語を「名詞」と「セリフ」に限定することで、見やすく表示することができた。加えて、コメントの部分をそのまま表示することで、記者が書いたものとコメントを視覚的に区別することができた。

一方で、リンクについているラベルの大きさが小さかったため、見づらくなってしまった。また、今回は「名詞」と「名詞」の間にある「動詞」と「副詞」に限定したため、「名詞」と「名詞」の間にない単語の表示がされていない。日本語は文章のメインとなる述語が一番後にくるという特徴があるので、各文の述語がこれらの図からは読み取れないことがわかる。

「助詞」の方は、主要となるものはうまく色分けをすることができた。しかし、実用面を考えると、事前に色ごとの特徴を説明する必要があるので、共起グラフとともに色分けの注釈をつける必要があると感じた。

7. 今後の展望

文章の内容を捉えるには、主語と述語の把握は不可欠である。そのため、名詞同士の間にない動詞の表示方法を考える必要がある。今回は全ての単語の重みを一定にして表示させた。そのため、どのワードが文章において重要なのかを読み取ることが困難であった。重みを利用することで、視覚的に重要な情報を素早く認識できると考える。また、表示された単語に元の情報をのせたリンクをつけることで、より詳細な情報を知りたいときに、簡単に対象の文章に辿り着ける。